# Moderné prístupy v optimalizácii

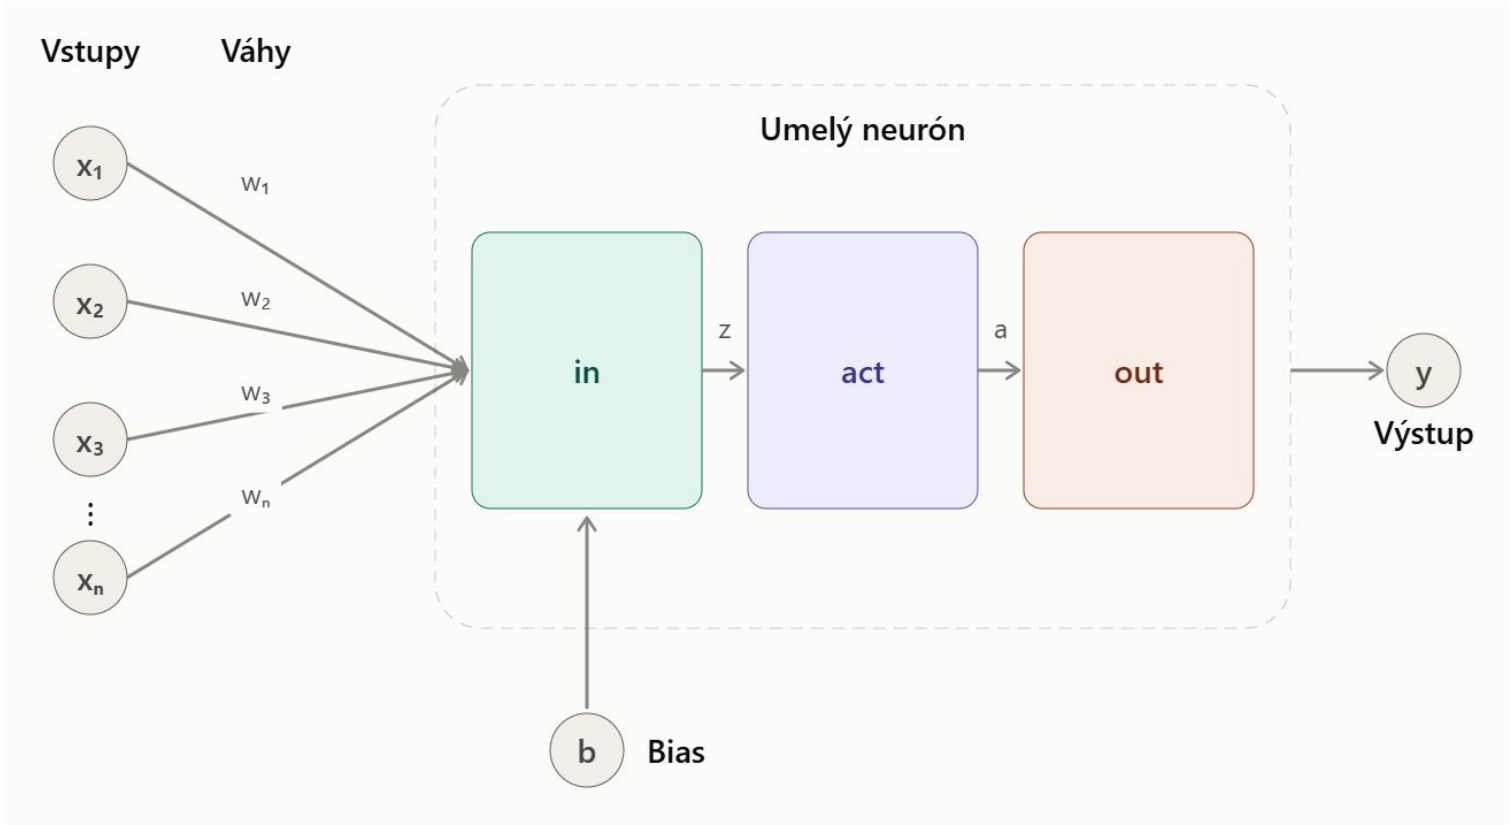
Optimalizácia trénovania neurónových sietí

prednáška 6

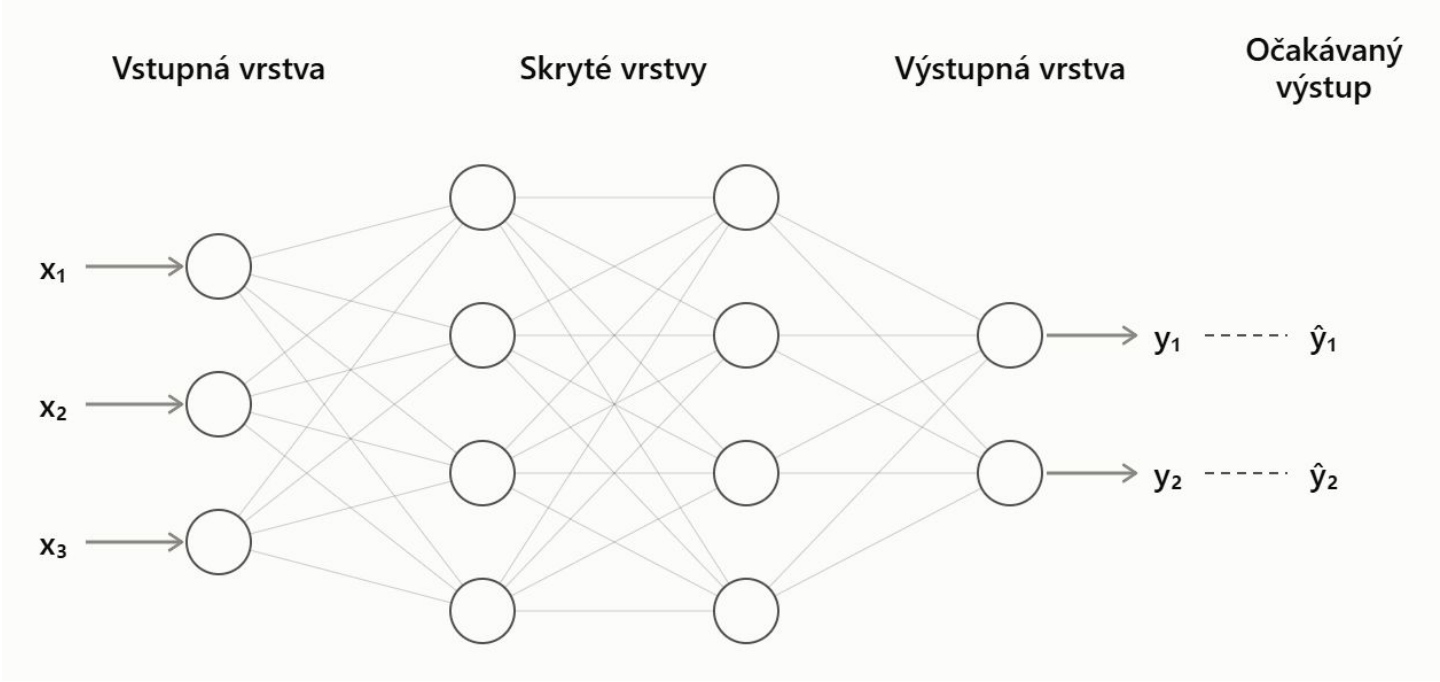
Ing. Ján Magyar, PhD.

ak. rok. 2026/2027 ZS

# Štruktúra umelého neurónu



# Základy trénovania neurónových sietí



# Backpropagation

$$\Delta w_i = -\alpha \frac{\partial L}{\partial w_i}$$

$$\frac{\partial L}{\partial w_i} = \frac{\partial L}{\partial out} \cdot \frac{\partial out}{\partial act} \cdot \frac{\partial act}{\partial in} \cdot \frac{\partial in}{\partial w_i}$$

$$w_i \leftarrow w_i - \alpha \frac{\partial L}{\partial w_i}$$

# Trénovanie ako optimalizačný problém

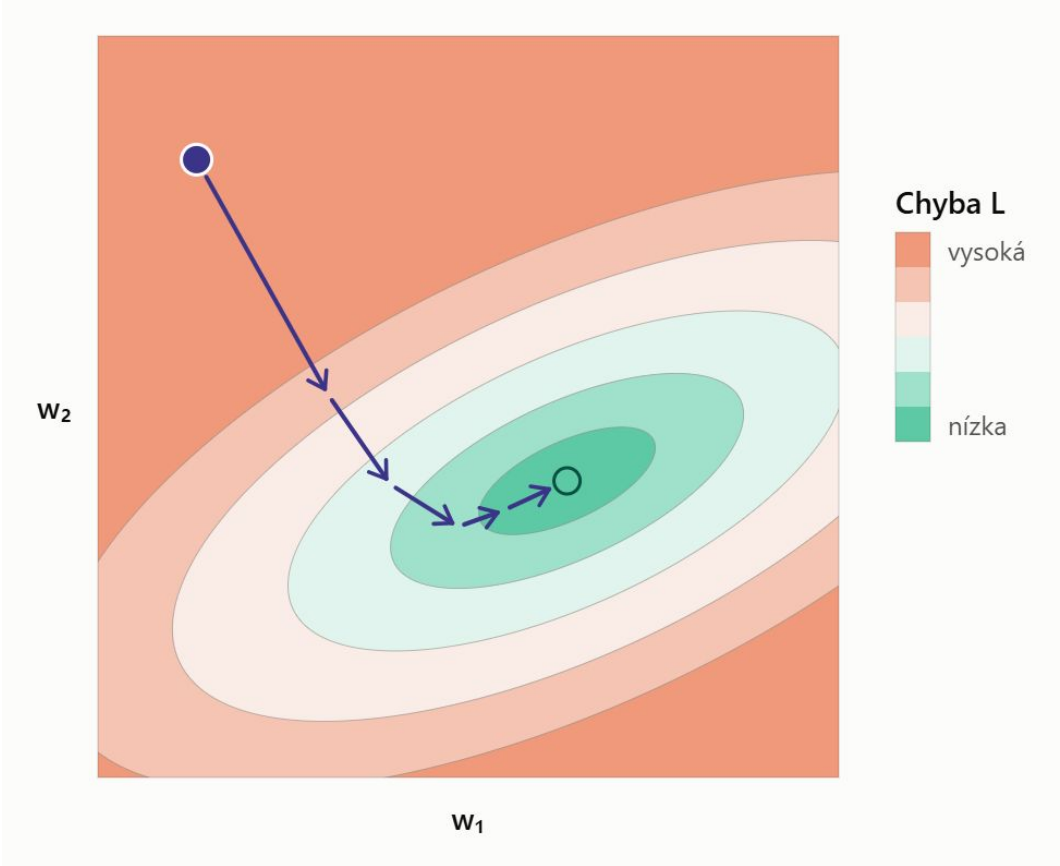
cieľom je nájsť vhodné nastavenie váh

cieľová funkcia = chyba

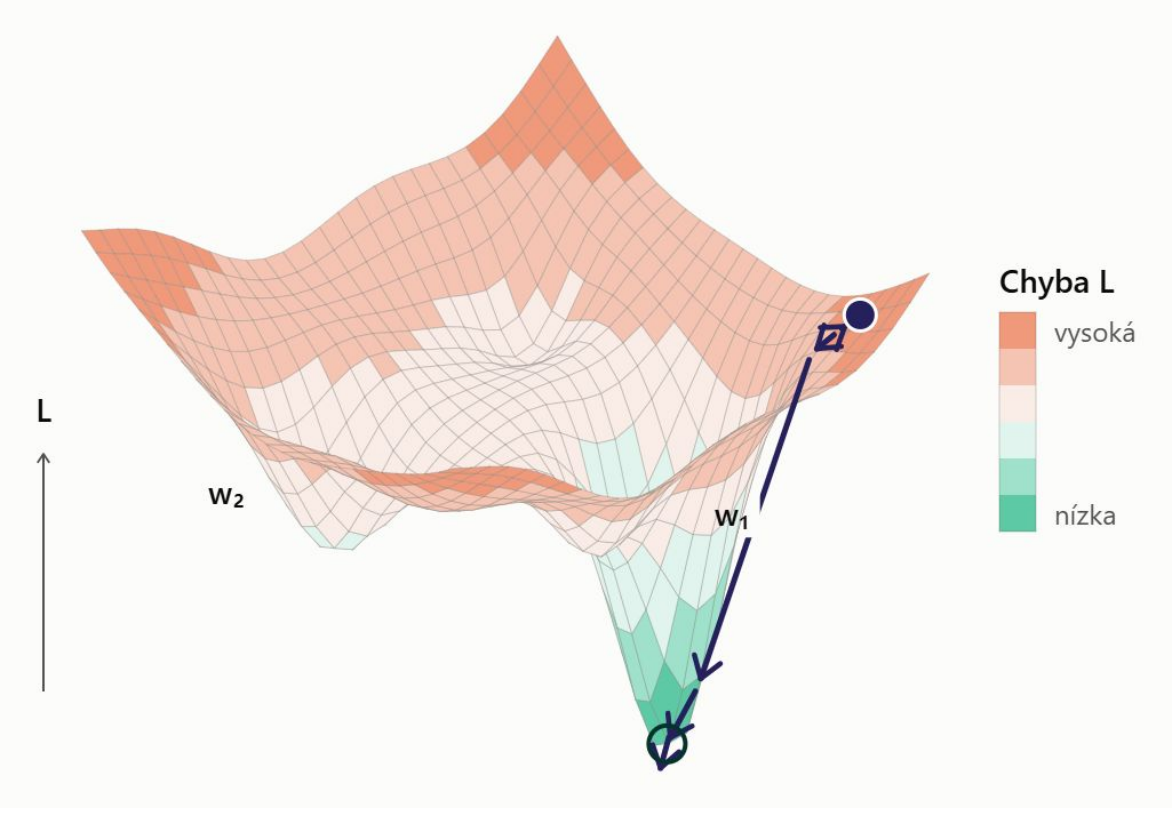
priestor prehľadávania = chybový priestor

riadené prehľadávanie podľa gradientu

# Trénovanie ako optimalizačný problém



# Trénovanie ako optimalizačný problém



# Hyperparametre trénovania

učiaci parameter

veľkosť batchu

architektúra

topológia

aktivačná funkcia

regularizácia a normalizácia

optimalizátor

# Optimalizácia hyperparametrov

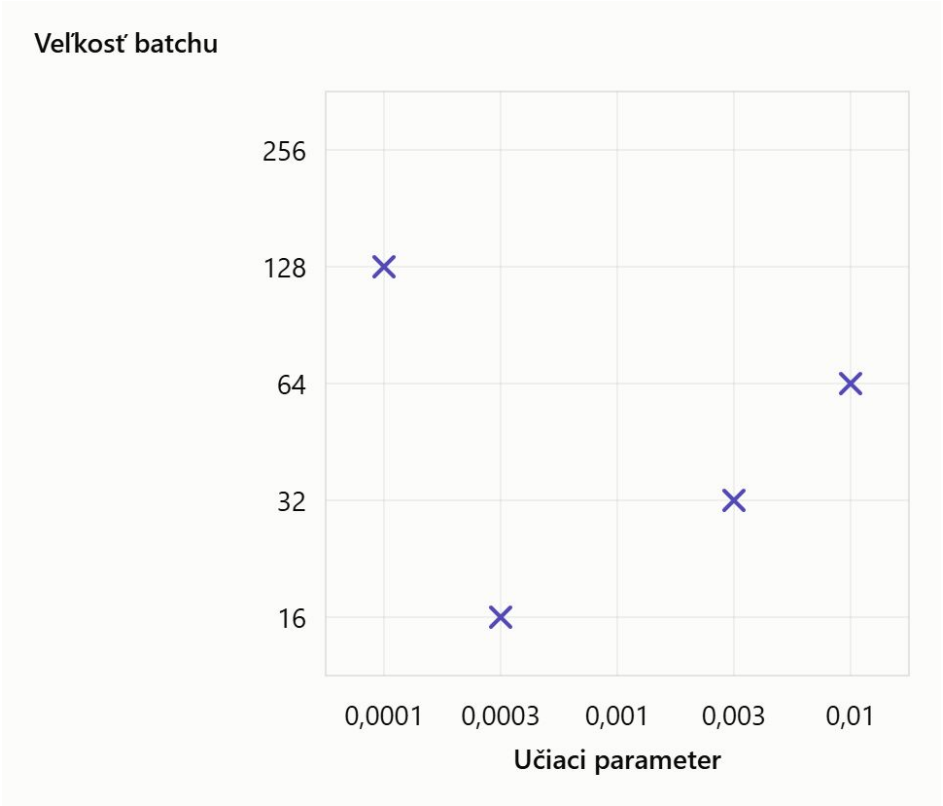
osvedčené hodnoty

grid search

Bayesova optimalizácia

metaevolúcia

# Grid search




sampling stratégie:

- uniform sampling
- normal sampling
- logarithmic sampling

# Metaevolúcia

jedinec reprezentuje jednu možnú konfiguráciu

účelová funkcia vyjadruje výkonnosť modelu na validačných dátach

selekcia úmerná s kvalitou, kríženie kombinuje hodnoty hyperparametrov

malá šanca nevalidných nastavení

masívna paralelizácia pre zníženie výpočtovej náročnosti

# Optimalizácia trénovacieho procesu

cieľom je dynamicky meniť parametre trénovacieho procesu

neoptimalizuje sa štartovací bod ale spôsob aktualizácie váh (kroky)

niekoľko štandardných optimalizátorov

rôzne optimalizátory pre rôzne typy údajov

rovnaké princípy sa dajú použiť pri ľubovoľnej gradientovej optimalizácii

# Learning rate decay

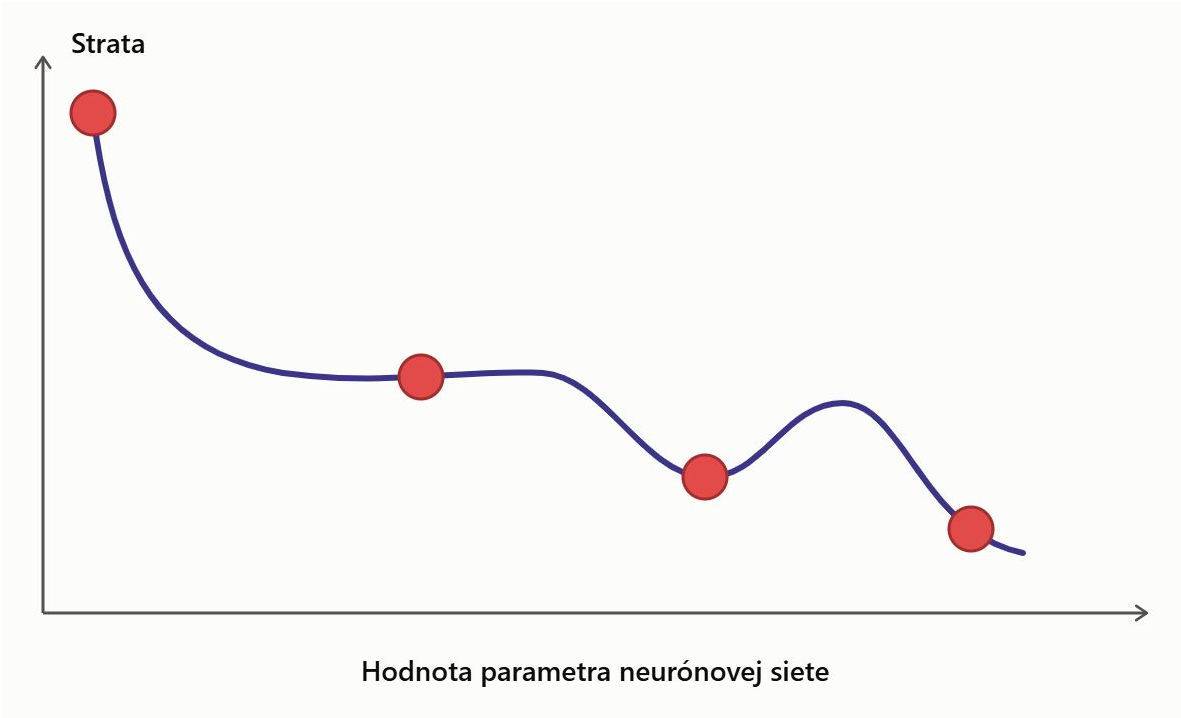
heuristika: spočiatku vieme spraviť väčšie kroky, ako sa blížime k minimu, spresníme prehľadávanie

$$\alpha_t = \alpha_0 \exp(-k \cdot t)$$

$$\alpha_t = \frac{\alpha_0}{1 + k \cdot t}$$

alternatívne kroková aktualizácia

# Momentum-based learning




$$\overline{V} \Leftarrow \beta\overline{V} - \alpha\frac{\partial L}{\partial \overline{W}}$$

$$\overline{\overline{W}} \Leftarrow \overline{\overline{W}} + \overline{V}$$

# Parameter-specific gradient descent

každý (hyper)parameter ovplyvní trénovania iným spôsobom = nemá zmysel všetky nastavovať rovnako

(hyper)parametre meníme dynamicky a nezávisle od seba

jednoduchá heuristika: kým gradient vyjadruje rovnaký smer, zvyšujeme dĺžku kroku, v opačnom prípade ju znížime

# AdaGrad

väčšie relatívne posuny ak gradienty sú konzistentnej veľkosti

$$A_i \leftarrow A_i + \left(\frac{\partial L}{\partial w_i}\right)^2 \quad \forall i$$

$$w_i \leftarrow w_i - \frac{\alpha}{\sqrt{A_i}} \left(\frac{\partial L}{\partial w_i}\right); \ \forall i$$

# RMSProp

podobná logika ako AdaGrad, ale so zabúdaním

$$A_i \leftarrow \rho A_i + (1-\rho)\left(\frac{\partial L}{\partial w_i}\right)^2 \quad \forall i$$

$$w_i \leftarrow w_i - \frac{\alpha}{\sqrt{A_i}}\left(\frac{\partial L}{\partial w_i}\right);\ \forall i$$

# AdaDelta

nahrádza učiaci parameter nepriamou náhradou

$$w_i \leftarrow w_i - \underbrace{\frac{\alpha}{\sqrt{A_i}} \left( \frac{\partial L}{\partial w_i} \right)}_{\Delta w_i}; \ \forall i$$

$$\delta_i \leftarrow \rho \delta_i + (1 - \rho)(\Delta w_i)^2 \quad \forall i$$

$$w_i \leftarrow w_i - \underbrace{\sqrt{\frac{\delta_i}{A_i}} \left( \frac{\partial L}{\partial w_i} \right)}_{\Delta w_i}; \ \forall i$$

# Adam

kombinácia AdaGrad a RMSProp s momentom

$$A_i \leftarrow \rho A_i + (1-\rho)\left(\frac{\partial L}{\partial w_i}\right)^2 \quad \forall i$$

$$F_i \leftarrow \rho_f F_i + (1-\rho_f)\left(\frac{\partial L}{\partial w_i}\right) \quad \forall i$$

$$w_i \leftarrow w_i - \frac{\alpha_t}{\sqrt{A_i}} F_i; \ \forall i$$

$$\alpha_t = \alpha \underbrace{\left(\frac{\sqrt{1-\rho^t}}{1-\rho_f^t}\right)}_{\text{Adjust Bias}}$$

# Gradient clipping

vyrovnáva efekt rôznych komponentov na základe aktuálnej hodnoty

value-based

norm-based

# Continuation learning

v skutočnosti chybové funkcie vytvárajú zložitý priestor prehľadávania

úprava optimalizačnej úlohy od jednoduchého variantu po zložitý

najčastejšie cez blurring = hodnotu nahradíme priemerom okolitých bodov

# Curriculum learning

zjednodušujeme riešenú úlohu alebo dáta

najprv naučíme model vyriešiť jednoznačné úlohy a následne pridávame zložitejšie príklady

potreba vyváženia dát aj v neskorších fázach trénovania

# Zhrnutie

základný princíp trénovania umelých neurónových sietí

hyperparametre neurónových sietí

optimalizácia hyperparametrov

optimalizácia gradientového zostupu

continuation learning a curriculum learning